

Przykład analizy z wykorzystaniem modelu regresji logistycznej

Autorzy: Piotr Nowakowski, Maciej Ogródnik, Jakub Peczyński

Cel:

Celem pracy było zaprezentowanie przykładowej analizy z wykorzystaniem modelu regresji logistycznej oraz ocena czynników wpływających na ryzyko wystąpienia udaru mózgu. Zastosowanie modelu logitowego było uzasadnione binarnym charakterem zmiennej objaśnianej, która informowała o wystąpieniu bądź braku udaru.

Teoria

Modele dwumianowe są najpopularniejszymi modelami, w których zmienna objaśniana jest zmienną jakościową. W modelach tych, p_i (prawdopodobieństwo) jest funkcją wektora wartości zmiennych objaśnianych x_i dla i -tego obiektu oraz wektora parametrów β :

$$P_i = P(y_i = 1) = F(\mathbf{x}_i^T \boldsymbol{\beta})$$

Jednym z nich jest model logistyczny, dla którego:

$$P_i = F(\mathbf{x}_i^T \boldsymbol{\beta}) = \frac{1}{1 + \exp(-\mathbf{x}_i^T \boldsymbol{\beta})}$$

Estymacja parametrów:

Do estymacji parametrów modelu wykorzystuje się metodę maksymalnej wiarygodności. Na podstawie funkcji log-wiarygodności:

$$l(\beta) = \sum_{i=1}^N y_i \log p_i + (1 - y_i) \log(1 - p_i) = \sum_{i=1}^N y_i x_i \beta + \log(1 - \exp(x_i \beta))$$

licząc pochodną po β_i :

$$\frac{\partial l(\beta)}{\partial \beta} = \frac{\partial}{\partial \beta} \sum_i y_i \beta^T x_i - \log(1 + e^{\beta^T x_i}) = \sum_i x_i \left(y_i - \frac{1}{1 + e^{-(\beta_0 + \beta_1 x_1 + \dots + \beta_k x_k)}} \right)$$

Równania są nieliniowe ze względu na parametry, dlatego też nie można podać analitycznych wzorów określających estymatory parametrów w modelu logitowym.

Wykorzystuje się w tym celu metody numeryczne oparte o metodę ważonych najmniejszych kwadratów (Fisher Scoring) lub o metodę estymacji Newtona-Raphsona.

Interpretacja parametrów:

- Jeśli $B_i > 0$, to przy wzroście wartości X_i wzrasta prawdopodobieństwo tego, że $Y = 1$
- Jeśli $B_i < 0$, to przy wzroście wartości X_i wzrasta prawdopodobieństwo tego, że $Y = 0$

(przy założeniu, że wartości pozostałych zmiennych nie ulegną zmianie)

Do interpretacji modelu logitowego wykorzystuje się również iloraz szans określony jako stosunek prawdopodobieństwa $Y = 1$ do prawdopodobieństwa, że $Y = 0$. Dla zmiennych ciągłych interpretacja może wyglądać następująco: jeśli X_j wzrośnie o jednostkę to iloraz szans zmieni się o $\exp(B_j)$ razy (ceteris paribus). Natomiast dla zmiennych zero-jedynkowych $\exp(B_j)$ oznacza, o ile razy zmienia się iloraz szans dla $X_j = 1$, w porównaniu z tym ilorazem dla $X_j = 0$.

Testy istotności:

Dla dużych prób można wykorzystać asymptotyczny test t-studenta.

Do weryfikacji istotności parametrów można również wykorzystać statystykę ilorazu wiarygodności $LR = 2(\ln UR - \ln LR)$, gdzie

- $\ln LR$ jest maksymalną wartością logarytmu funkcji wiarygodności dla modelu zawierającego jedynie wyraz wolny.
- $\ln UR$ jest wartością maksymalną logarytmu wiarygodności dla pełnego modelu.

Ocena zgodności:

Do oceny jakości modelu wykorzystuje się często trafność prognoz uzyskiwanych na jego podstawie. Za miarę może służyć zliczeniowy R^2 , który określa udział poprawnie prognozowanych przypadków w łącznej liczbie przypadków.

Za odpowiednikiem współczynnika determinacji z modelu regresji liniowej może służyć pseudo – R^2

$$pseudo-R^2 = 1 - \frac{\ln \hat{L}_{UR}}{\ln \hat{L}_R}$$

Przyjmuje wartość 0, jeśli $b_1 = b_2 = \dots b_k = 0$ oraz wartość 1 w przypadku idealnego dopasowania, gdy $\hat{y}_i = y_i$.

Prognostowanie na podstawie modelu

Na podstawie oszacowanego modelu można określić prognozy:

$$\hat{y}_i = 1, \text{ jeśli } \hat{P}_i > p^*$$

$$\hat{y}_i = 0, \text{ jeśli } \hat{P}_i \leq p^*$$

Za wartość odcinającą można przyjąć wartość 0,5, jednak w przypadku niebilansowanej próby, proponuje się, żeby wynosiła n_1/n , gdzie n_1 - liczba obserwacji dla których Y przyjmuje wartość 1.

Analiza

Dane wykorzystane w tym badaniu dotyczą pacjentów i stanowią podstawę do estymacji modelu logitowego, którego celem jest ocena ryzyka wystąpienia udaru mózgu.

Opis zmiennych:

1) Zmienne niezależne:

- Male - zmienna binarna przyjmująca wartości: 0 – kobieta, 1 - mężczyzna
- Age - wiek badanej osoby
- Hypertension (nadciśnienie) - zmienna binarna przyjmująca wartości: 0 – nie posiada, 1 – posiada
- Heart_disease (problemy z sercem) - zmienna binarna przyjmująca wartości: 0 – nie posiada, 1 – posiada
- Ever_married (czy kiedykolwiek w związku małżeńskim) - zmienna binarna przyjmująca wartości: 0 – nie, 1 – tak
- Urban (rodzaj zamieszkania) - zmienna binarna przyjmująca wartości: 0 - wieś, 1 – miasto
- Avg_glucose_level - średni poziom glukozy we krwi
- BMI - wskaźnik masy ciała

2) Zmienna zależna:

- Stroke (udar mózgu) - zmienna binarna przyjmująca wartości: 0 – osoba nie posiadała, 1 – osoba posiadała

Badanie istotności parametrów:

Wstępny model prezentuje się następująco:

Coefficients:					
	Estimate	Std. Error	z value	Pr(> z)	
(Intercept)	-7.690771	0.544572	-14.123	< 2e-16	***
age	0.069785	0.005279	13.219	< 2e-16	***
Male	0.048309	0.140434	0.344	0.73085	
hypertension	0.397660	0.163556	2.431	0.01504	*
heart_disease	0.311374	0.189556	1.643	0.10046	
ever_married	-0.196714	0.219370	-0.897	0.36987	
Urban	0.107019	0.138155	0.775	0.43856	
avg_glucose_level	0.003942	0.001200	3.284	0.00102	**
bmi	0.009163	0.012440	0.737	0.46137	

Widzimy, że tylko trzy zmienne są istotne statystycznie, dlatego w celu uproszczenia modelu przeprowadzimy regresję krokową wstecz, eliminując zmienne nieistotne.

Po zastosowaniu regresji krokowej wstecz (funkcja `step(model, direction = "backward")` do ostatecznego modelu wchodzi następujące zmienne: `age`, `hypertension` oraz `avg_glucose_level`.



Coefficients:					
	Estimate	Std. Error	z value	Pr(> z)	
(Intercept)	-7.540373	0.356877	-21.129	< 2e-16	***
age	0.070122	0.005086	13.786	< 2e-16	***
hypertension	0.407427	0.162757	2.503	0.012305	*
avg_glucose_level	0.004345	0.001158	3.754	0.000174	***

Postać modelu:

$$\ln\left(\frac{P}{1-P}\right) = -7,5404 + 0,07 \cdot age + 0,4074 \cdot hypertension + 0,0043 \cdot avg_glucose_level$$

Interpretacja parametrów:

- age (0.0701): Wartość dodatnia. Wraz ze wzrostem wieku, prawdopodobieństwo wystąpienia udaru rośnie, przy cp.
- hypertension (0.4074): Wartość dodatnia. Nadciśnienie zwiększa szansę na wystąpienie udaru, przy cp.
- avg_glucose_level (0.0043): Wartość dodatnia. Wyższy poziom glukozy wiąże się z wyższym ryzykiem, choć wpływ jednostkowy wydaje się mały.
- (Intercept) (-7.5404): To wartość logarytmu szansy w sytuacji, gdy wszystkie zmienne niezależne wynosiłyby 0



Macierz klasyfikacji:

	FALSE	TRUE
0	4022	711
1	99	149

Oznacza ona, że:

- Model poprawnie przewidział brak udaru u 4022 osób.
- Model poprawnie wykrył udar u 149 osób.
- Model przewidział 711 udar, u osób, które go nie miały.
- model nie wykrył udaru u 99 osób, które go doznały.

Zliczeniowy R^2 :

$$\text{Zliczeniowy } R^2 = \frac{n_{00} + n_{11}}{n}$$

Uzyskany wynik 84% mówi nam, że nasz model sklasyfikował poprawnie 84% obserwacji.

Iloraz szans:

	age	hypertension	avg_glucose_level
	1.0726391282	1.5029463783	1.0043547174

Odczytując wartości, jesteśmy w stanie stwierdzić, że:


Age – wzrost wieku o jeden rok, zwiększa szansę udaru o średnio 7,3% przy ceteris paribus.

Hypertension - jeśli posiada nadciśnienie, to szansa udaru wzrasta średnio o 50,3% przy ceteris paribus.

Avg_glucose_level - wzrost średniego poziomu glukozy we krwi o jedną jednostkę podnosi szansę udaru średnio o 0.4% przy ceteris paribus.

Krzywa ROC:

Nasza krzywa ROC wygina się mocno w stronę lewego rogu. Oznacza to, że nasz model ma wysoką czułość, zachowując przy tym niski poziom fałszywych alarmów. Ponadto, obszar pod wykresem wynosi 0,84 co tylko nas w tym upewnia.



Podsumowanie:

Wykorzystaliśmy dane medyczne pacjentów w celu identyfikacji istotnych czynników ryzyka udaru. Wstępny model obejmował pełen zestaw zmiennych objaśniających, jednak na podstawie testów istotności statystycznej oraz regresji krokowej wstecz uzyskano uproszczony model końcowy. Ostatecznie istotny wpływ na prawdopodobieństwo wystąpienia udaru wykazały trzy zmienne: wiek, nadciśnienie oraz średni poziom glukozy we krwi.

Interpretacja parametrów oraz ilorazów szans potwierdziła, że ryzyko udaru rośnie wraz z wiekiem, jest istotnie wyższe u osób z nadciśnieniem oraz zwiększa się wraz ze wzrostem poziomu glukozy we krwi. Ocena jakości modelu wskazuje na jego dobre własności predykcyjne – zliczeniowy R^2 na poziomie 84% oznacza wysoki odsetek poprawnych klasyfikacji, natomiast wartość AUC równa 0,84 świadczy o dobrej zdolności modelu do rozróżniania osób zagrożonych udarem i niezagrożonych.

Podsumowując, przeprowadzona analiza potwierdza użyteczność regresji logistycznej w badaniach medycznych i analizie ryzyka zdarzeń binarnych. Uzyskane wyniki są zgodne z wiedzą medyczną i wskazują na kluczową rolę wieku, nadciśnienia oraz poziomu glukozy jako istotnych czynników ryzyka udaru mózgu. Model może stanowić wartościowe narzędzie wspomagające ocenę ryzyka, przy czym należy pamiętać o jego uproszczonym charakterze i możliwości dalszego rozszerzenia o dodatkowe zmienne lub metody walidacji.